

5.2.3。猛犸 ( 俊彦Wu等人。 )

吴等人。提出了一个单向网络版的框架，结合深特征提取和统计功能，混合自动预测DR和DME严重程度评分。对于DME，他们用DenseNet ( landola等人，2014 ) 直接预测的严重程度评分。而对于DR，Kaggle训练数据集，使用通过动态采样机制pretrain的DenseNet模型来平衡训练实例和ne调谐使用稍后音响IDRid数据集。最初，所有图像的背景被裁剪和调整大小以512 × 512个像素。后来，形态开启和关闭被用来保持亮区和暗区。例如，形态开可以擦除EXS和突出的MA。然而，关闭操作可以消除MAS和维护E XS。这些操作可用于CLASSI网络阳离子的降噪SPECI科幻C水平，例如，DME的风险，只依赖于EXS的位置。此外，几个标准数据增强方法 ( 如在所示 表6 ) 也被使用。均方误差 ( MSE ) 和交叉熵与网络连接已经类被用来训练用于优化网络和SGD损失功能。初始学习速率设定为0.0005具有0.1每30个时期后递减。初始训练用50个时期由时期200和FI NE-调谐完成。随后，网络最终预测之前删除的最后一层，它的统计特征被聚集在一起为推进树。具体来说，进行了50伪随机扩增以获得从最后第二FC层 ( 4096尺寸 ) 5 0个输出，然后对每个图像50个的特征向量的平均值和标准偏差被计算，并且然后两个载体连接在一起用于训练在LightGBM。从音响NE-调谐实验倒数第二层的输出被用于训练混合模型，从战略DR Kaggle挑战队O\_O的解决方案采用。最后，对于疾病分级预测，梯度推进树模型是建立从预先训练网络和网络连接的NE-调谐网络的组合倒数第二层上。

对于DME的分级，构件细胞神经网络的网络连接的最终层由3个神经元，和权重矩阵的 一种1，一种2 分别为3 × 3，初始化为

$$\begin{bmatrix} 1/3 & 0 & 0 \\ 0 & 1/3 & 0 \\ 0 & 0 & 1/3 \end{bmatrix} \quad (9)$$

对于训练，他们合并IDRid和Kaggle训练集。结构的参数进行了SGD算法在189个50分别时期找到了DR和DME CLASSI网络阳离子任务。学习率设置为0.0001。对数据集进行DR和DME所需的训练时间分别为96.6 ( 189时期 ) 和23.4 ( 50时期 ) 小时。这项工作的实施是在MATLAB 2017b完成。该培训使用的NVIDIA TITAN X GPU卡执行具有的单精度性能7万亿次，

336.5 GB /秒的存储器带宽，3072个CUDA内核和12 GB存储器。

5.2.5。AVSASVA ( Varghese表示亚历克斯等人 ) 中

亚历克斯等人。预先训练细胞神经网络的使用的合奏 ( 上ImageNet数据集 )，即，ResNets ( 他等人。年，2016年 ) 和DenseNets ( landola等人，2014 ) 疾病分级的任务。对于DR分级，CNN两个合奏的，即“主”和“专家”被用来CLASSI网络ERS。主CLASSI音响ER被训练到眼底图像作为4类即之一分类; 正常，轻度NPDR，中度NPDR或S- ( N ) -PDR，通过严重NPDR和PDR形成的类。专家CLASSI音响ER被重症NPDR或PDR图像专门训练和被利用以划分输入图像作为上述类别中的一个。在推理，每个眼底图像调整到256的尺寸 × 256个像素。对于眼底图像DR的分级的任务，他们通过代网络PyTorch定义“十大裁剪”功能使用的测试时间增强。这些图像是通过网络连接主CLASSI音响ER，然后通过专家CLASSI音响呃首先通过，只有当图像被划为S- ( N ) -PDR由主CLASSI音响ER。该网络最终预测是通过使用多数表决方案来实现的。

5.2.4。:Arngiml ( 巴拉兹Harangi等人 ) 中

Harangi等。经由两个AlexNet的融合 ( 提出了视网膜图像的CLASSI音响阳离子的方法 Krizhevsky等人，2012 ) 和GoogLeNet ( Szegezy等人，2015年 )。对于这个目的，它们除去FC和CLASSI音响阳离子层和通过插入接头FC层它们互连，随后为网络连接最终预测经典SOFTMAX / CLASSI音响阳离子层。以这种方式，单个网络架构被创建，其允许培养构件CNN的同时。对于每一个 一世 ( N ) 让我们通过表示构件CNN的的音响NAL FC层的输出

$$\begin{matrix} (N)^{\wedge} & (N) \\ \text{该}_1 & \text{该}_2 \end{matrix} \text{的FC层}$$

他们合奏聚集他们通过

$$\text{该} (N) = \text{一种}_1^{\wedge} \text{该}_1 + \text{一种}_2^{\wedge} \text{该}_2 \quad (6)$$

其中权重矩阵 一种1，一种2 按大小的5 × 5和初始化

$$\begin{matrix} \text{一种}_1 = \text{一种}_2 = \begin{bmatrix} 1/5 & 0 & 0 & 0 & 0 \\ 0 & 1/5 & 0 & 0 & 0 \\ 0 & 0 & 1/5 & 0 & 0 \\ 0 & 0 & 0 & 1/5 & 0 \\ 0 & 0 & 0 & 0 & 1/5 \end{bmatrix} \end{matrix} \quad (7)$$

乐团的最后两层是一个SOFTMAX和CLASSI网络阳离子之一。让 该 ( N )

SM是一个前层的输出，该MSE是用于优化的损失函数：

$$MSE = 1 \frac{NN=1}{2 \tilde{n}} \left( \sum_{\text{该} (N)} \text{SM} - \text{该} (N) \right)^2 \quad (8)$$

在训练阶段期间，反向传播施加经由调整部件细胞神经网络和权重矩阵的所有参数，以最小化损失 一种1，一种2。

对于DME分级，二合奏在一个与其他方法进行了培训。合奏1被训练到输入是“没有明显EXS图像”分类 ( 0级 ) 或“图像EXS的存在” ( 1级和2级 )，而合奏2被训练的图像作为“级分类2” DME或不 ( 0级和1级 )。在推理时，调整大小后的图像被馈送到合奏，并通过利用一组用户自定义网络连接的规则两个预测合成而获得的连接的最终预测。简要地y，则userde音响定义规则是：图像被划为0级DME如果合奏1和合奏2预测没有EXS的和分别不存在2级DME的。一个场景，其中合奏2预测2级DME的存在下，图像是根据类别CLASSI音响ED“2级DME”不管来自集合1中的预测的最后，

对DR和DME两种模型中与预训练权重初始化和网络的参数，通过减少与ADAM交叉熵损失作为优化器优化。学习率初始化为10<sup>-3</sup>对于DR和10<sup>-4</sup>二甲醚。对于DR，学习率每个实例都减少了10%的因素，当验证失败，损失下降。每个网络被训练为30个历元和产生最低验证损失被用于推理的模型参数。为DME，学习率退火逐步以10的步长和学习的0.9率衰减值的乘法因子。

5.2.6。:Arngin2 ( 巴拉兹Harangi等人 ) 中

Harangi等。联合自我提取，基于CNN的功能与传统的，手工制作的那些疾病CLASSI网络阳离子。他们作案科幻编AlexNet ( Krizhevsky等人，2012 )，以允许的嵌入

经由FC层手工特征。通过这种方式，他们创造，可以以通常的方式进行培训，另外使用领域知识的网络结构。他们延长了FC层，得到 *FC保留层*，原本含有AlexNet 4096个神经元通过加入含有手工特征68维向量。然后， $4164 \times 5$  ( 或 $4164 \times 3$  DME ) 层 *FC层*被认为是DR ( 或DME ) CLASSI网络阳离子任务。这样一来，无论是网络最终称量 *FC层*是手工制作的特点，获得和4096个AlexNet特点是由反向传播训练。

以获得由CNN使用68个手工特征，他们使用了一个图像的水平两个病变SPECI音响Ç方法。所述amplitudefrequency调制 ( AM-FM ) 从图像中提取方法信息通过分解在不同尺度的绿色通道分成AM-FM分量 ( 哈夫利切克, 1996年 )。其结果，得到30-元件的特征向量，从而重新FL学分强度，几何形状和结构的纹理图像中包含的 ( 阿古等人, 2010 )。而于与病变MA和EX提取功能，它们使用两个探测器合奏 ( 而安塔尔豪伊杜, 2012; Nagy等人, 2011 )，其包括一组<预处理方法 ( PP )，候选提取 ( CE )>的的组织成一个投票系统对。这样的<PP, CE>对通过施加PP的视网膜图像和CE到其输出形成。以此方式，一个<PP, CE>对抽取一组肿瘤候选者的从所述输入图像，作为一个单一的检测器算法。他们用这些合奏的输出，以获得与马的和EX的数量和大小38种功能。该体系结构的参数由SGD算法在85个50对历元DR和DME分别优化。训练时间分别为83.1 ( 85时期 ) 和46.2 ( 50时期 ) 小时的数据集对DR和DME。这项工作的实施是在MATLAB 2017b完成。已经使用NVIDIA TITAN X GPU卡7万亿次的单精度，336.5 GB进行训练/ S的存储器带宽，3072个CUDA内核和12 GB存储器。

5.3. 次挑战 - 3：视盘和黄斑中心凹检测

对于给定的图像，该任务旨在得到解决本地化OD和中央窝。此外，它寻求获得一个像素为外径 ( OD分割 ) 的概率。的方法发明内容详述如下：

5.3.1. Deepdr (Ling Dai et al.)

Dai等。提出了一种新颖深刻的定位方法，它允许粗TO-Fi无线功能，NE编码捕获全局和局部结构眼底图像的策略，同时在模拟OD和中央凹本地化的双任务学习问题。他们利用先验知识，如标志性建筑的数量和它们的几何关系，以可靠地检测OD和中央凹。具体来说，他们第一个设计的一个全球性的CNN编码器 ( 带RESNET-50的骨干网 ( 他等人。年, 2016年 ) ) 通过求解回归任务本地化OD和中央凹中心作为一个整体。所有的MAX-汇聚层，平均池层代替相比原来RESNET架构，由于这样的事实，MAX-池可能会失去一些有用的像素级别的信息，回归预测坐标。该步骤用于同时执行两个检测任务，因为OD和中央凹之间的几何关系，多任务学习的性能比单个任务更好。这个全球CNN编码器部件的预测输出的坐标被用于检测靶OD和中央凹的边界框。则当前中心坐标重新连接通过本地编码器定义 ( 具有一个骨干网络VGG-16 ( 西蒙尼扬和Zisserman 2014 ) )，其中只有本地化的OD中心或与其相关的边框中央凹中心。在培训阶段，他们设计了一个有效的数据增强方案来解决INSU FFI cient训练数据的问题。特别是，建立一个本地编码器的训练集，随机选择的包围盒

基于地面实况，为每个对象不同的位置和规模的几个边框进行裁剪。本地编码器可重复使用多次以接近目标坐标。本地编码器是为全面重新连接宁中心重复两次。这三款车型从预训练ImageNet网络初始化，并通过中心坐标回归取代了网络的最后FC层和SOFTMAX层。在中央位置的回归损失是欧几里德损失。全球和本地编码器的作家网络版损失函数为0.045 ( 大号 *从*

大号 *FO V B* ) 和0.045 ( 大号 *OD / 大号中央凹* ) 分别。哪里 大号 *FROM* 和 大号 *小从* 针对OD和凹，和缩放因子的损失被引入，因为原来的欧氏距离是在实践中收敛过大。所提出的学习模型是在来自Caffe框架中实现和使用SGD动量训练。所述FC层为中心回归，从零均值高斯分布与标准偏差0.01 0.001初始化。偏见被初始化为

0全局编码器被训练为200个历元，本地编码器 ( OD和中央凹两者 ) 为分别为30个时期。全球编码器的批量大小为16和64的其他两个本地编码器。学习率设定为0.01，并通过10当误差高原划分。

5.3.2. VRT ( Jaemin她等人 ) 中

儿子等人。提出由U形网 ( 的OD分割模型 Ronneberger等人, 2015年 ) 和CNN采用一个血管图像，并输出 $20 \times 20$ 激活图，其倒数第二层被级联到U形网的瓶颈层。最初，原始图像进行裁剪 (  $3500 \times 2848$  个像素 )，衬垫 (  $3500 \times 3500$  个像素 )，然后调整大小 (  $640 \times 640$  个像素 )。每个图像与它的平均值和标准差 ( SD ) 标准。当计算的平均值和SD，值小于10 ( 在黑色背景通常伪像 ) 被忽略。用外部网络制备容器的图像 ( 她等人, 2017年 )。从0到1的像素值在容器中图像范围它使用外部数据集DRIONSDB ( Carmo na等, 2008年 ) 和DRIVE ( 面包车Ginneken等人, 2004年 ) 备有分别OD和容器基础事实。对于扩增，所述眼底图像是一个FFI NE-变换和另外OD被裁剪和随机放置在图像上进行的次数的随机数 ( 0~5 )。这增强做是为了防止网络不受亮度完全分割OD。眼底图像和血管分割的对在640分辨率被作为输入提供和OD分割  $\times 640$  和 $20 \times 20$ 个像素给出的地面实况。二进制crossentropy被用作作用于两个U型的净损失函数和血管网络的损失 大号 *从* = 大号 *从* - 从  $\times 0.1 \times$  大号 *V B*。共有800个时代是通过亚当优化训练和学习减少与超参数 *b*<sub>1</sub> = 0.5，*b*<sub>2</sub> = 0.999。学习率为 $2 \times 10^{-4}$ 直到400个历元和 $2 \times 10^{-5}$ 直到最后。重量和偏见与Glorot初始化方法进行初始化 ( Glorot和Bengio, 2010 )。

他们还提出了其中两个分支被专用于为OD位置预测和中央凹从血管 ( 血管分支 )，另两个分支的目标是预测来自眼底和血管 ( 主要分支 ) 的位置的四个分支模式。类似于OD分割，血管分支的倒数第二层深度级联到主要分支。导出表示包含一个解剖标志的概率的激活地图后，硬编码矩阵乘以获得坐标。原始图像进行裁剪作为分割任务，并用相同的方法标准化，后来由佛罗里达州的IP和旋转安心的实施力度增强。采用平均绝对误差作为损失函数为两路输出与损失 大号 *从* = 大号 *从*  $\pm 0.3 \times$  大号 *V B*。SGD与0.9亚当斯捷罗夫势头的优化使用。学习速率设置为 $10^{-3}$ 从1 st 500 日历元和 $10^{-4}$ 从501 日

到1000 日时代。所有执行于Keras做2.0.8

与TensorFlow使用具有8 TITAN X ( 帕斯卡 ) 的服务器后端1.4.0。源代码可以在 <https://bitbucket.org/woalstdn84>和科幻阳离子, 边界框回归和预测面具。通过该方法, OD的OD的定位和中央凹, 和分割可以直接实现。isbi\_2018\_fundus\_challenge。

5.3.3。ZJU BII-SGEX ( Xingzheng LYU等人 ) 中

吕等人。利用面膜R-CNN ( 他等人, 2017年 ) 定位和段OD和中央凹同时。它扫描图像和由2D边界框生成区域的建议。然后这些提案CLASSI音响编到不同的类别, 并且计算针对每个对象的二元掩模。他们Fl rstly预处理原来的视网膜图像到固定成本尺寸为网络输入。特征提取器 ( RESNET-50 ) 与特征金字塔网络 ( FPN ) 生成在不同尺度, 其可用于关注区域 ( ROI ) 的提取区域特征地图。然后, 区域提案网络 ( RPN ) 在扫描特征地图和定位包含对象的区域。最后, R OI头网络 ( RHN ) 被用来获得的标签, 面膜, 并重新连接定义边界框对每个ROI。他们也纳入视网膜图像的先验知识作为后处理步骤, 以提高模型的性能。Almazroa等人, 2018 ) ( 以OD获月和BinRushed, 6 05个图像 ) 面罩提供。他们应用转移学习技术来训练模型。他们Fl rstly冻结FPN和RPN网络的所有层, 然后连接NE-调整所有层训练RHN网络。该模型是在TensorFlow 1.3和Python实现3.4 ( 源代码是MODI音响从编 阿卜杜拉 ( 2017年 ) )。学习率0.001开始, 使用0.9的势头。网络用20个历元上训练一个GPU ( 特斯拉K80 )。

5.3.4。IITkgpKliv ( Oindrila Saha等人 ) 中

Saha等。SegNet使用 ( Badrinarayanan等人, 2015年 ) 在段病变和OD的心理状态。OD在同样的问题病划分作为附加类, 以便该模型可以更好地区分EXS和OD它们具有类似的亮度水平。然而, 相比于原始SegNet, 所述音响最终解码器输出被馈送到S形层, 以独立地产生类概率针对各像素在7个信道。每个信道的大小与输入图像相同的: 536 × 356个像素, 在范围由激活的[0, 1]其中0对应于背景和1至相应的类的存在。除了5班

即MA, HE, SE, EX和OD, 两个附加的类: ( i ) 视网膜磁盘不包括病变和OD, 和 ( ii ) 黑色背景形式的7个信道。图像被下采样到536 × 356个像素, 保持纵横比。此外, Drishti-GS ( Sivaswamy等人, 2014 使用 ) 的数据集进行数据扩充以考虑不存在病变的情况下。此外, 水平, 垂直和180°

FL ipped拍摄的原始图像的版本。该网络是使用二进制交叉熵损失函数和亚当优化与学习率10位训练有素-3和  $b = 0.9$ 。基于验证损失的训练早期停止采用, 以防止过度拟合。据观察, 确认损失后开始200个时代增加。一个更SOFTMAX层用于跨渠道的每个类归一化的像素值的S型层之后引入。分割的输出音响应受上采样为每个类4288 × 2848个像素。所有实现使用2个英特尔至强E5 2620处理器的V3与GTX TITAN X GPU 12 GB RAM和64 GB 的系统内存在PyTorch完成。

5.3.5。SDNU (Xiaodan Sui et al.)

Sui等。用过的面膜R-CNN ( 他等人, 2017年 ) 解决一切该子挑战任务。面膜R-CNN提出了基于候选对象边界RPN箱来达到目的OD和中央窝定位上可以实现精确的目标检测。同时, 它也可以得到在面罩预测分支的OD段。面膜R-CNN的头部结构 ( ResNet101作为主链 ) 由用于clas-三个并联支路

他们重新培训网络获得该框架的新的权重参数。在训练阶段, 这一挑战的数据集由FL ipping增强, 调整和10倍交叉验证训练。培训2000时代后, 得到最后的训练模型。他们实现了这个算法TensorFlow, 它是在8个NVIDIA TITAN XP的GPU的处理。实验环境在Ubuntu下建立

16.06。

5.3.6。CBER ( ANA/门多萨等人 ) 中

门多萨等人。提出了手工制作的功能, 基于对该次挑战的定位和分割任务的做法。不同的方法已被开发用于检测和分割这些结构中, 主要是基于颜色和血管信息。在这种挑战的背景下提出的方法包括三个相互依存的模块。每个模块执行单个任务: OD定位, OD分割或中央凹定位。而负责的OD定位和分割模块是两种方法的改进版本以前发表的 ( 门多萨等人, 2013; Dashtbozorg等人, 2015年 ), 提出了小窝定位的方法是全新的。最初, 与OD定位相关联的所述模块接收的眼底图像和段的视网膜血管系统。此后, 容器的方向的病被计算并与在顺序中的图像强度, 以网络连接的第二OD中心坐标相结合。对于OD分割, 负责此项任务的模块使用OD中心去科幻宁的区域的位置, 滑动频带滤波器 ( 佩雷拉等人, 2007; 伊斯特英等人, 2012 ) 被申请;被应用。被发现并用于划定边界OD其产生的最大滤波器响应支撑点的位置。由于黄斑中心凹-OD距离和OD直径之间的关系被称为 ( Jonas等人, 2015年 ), 负责中央凹本地化模块通过去音响宁开始从OD位置和直径的搜索区域。然后中央凹中心被分配给该区域内部的最暗点。

6.评估措施

根据不同的评价指标, 每个子挑战的性能进行了评估。被用于不同的子挑战如下评价措施:

6.1。次挑战 - 1

在此子挑战的算法病划分任务的性能提出使用灰度图像和可用的二进制口罩进行了评价。如在病变分割 ( 多个 ) 任务背景压倒前景高度不平衡的情况下, 此任务的性能, 使用精度下面积 ( 测量 又否阳性预测值 ( PPV ) ) 召回 ( 又否

灵敏度 ( SN ) 曲线 ( AUPR ) ( Saito和Rehmsmeier, 2015年 )。

$$SN = \frac{\text{真阳性真阳性} + \text{假阴性}}{\quad} \quad (10)$$

$$PPV = \frac{\text{真阳性真阳性} + \text{假阳性}}{\quad} \quad (11)$$

是通过阈值在33倍等距隔开的实例的结果, 即所得到的曲线[0, 8, 16, 在灰度级256]或[0, 0.03125, 0.0625, . 1]的概率。该AUPR提供了一个单科幻古尔措施 ( 又否 值平均精度 ( MAP ) ), 上计算的Set-B, 被用来排名参与方法。用于物体检测所述的可视PASCAL对象类此性能度量 ( VOC ) 挑战 ( 爱华灵威等人, 2010 )。

该AUPR措施是比较现实的 ( Boyd等, 2013; Saito和Rehmsmeier, 2015年 ) 以用于通过下接受者操作特征 ( ROC ) 曲线的区域中的病变的分割性能。

6.2。次挑战 - 2

为了让DR和DME专家通过标签来表示  $DR_G(N)$  和  $DME_G(N)$  )。而  $DR_{\hat{G}}(N)$  和  $DME_{\hat{G}}(N)$  是预测结果, 然后正确实例是当DR和DME专家标签与两个DR和DME的预测结果一致的情况下。因为这样做, 甚至有些渗出可分为轻度DR的存在, 其在视网膜上的位置也是一个重要的决定因素 ( 检查DME ) 决定疾病的整体档次。例如, EXS存在在黄斑区可影响患者的视力在更大程度上, 因此, 它应被优先处理转诊 ( 否则可能被遗漏或起因于治疗与仅DR等级的本公约的延迟 ) 在自动筛选系统。因此, 疾病分级性能精度为本子挑战, 从CSV格式提交测试图像的结果 ( 即  $N=103$  ) , 通过以下步骤获得 算法1 如下:

算法1: 的疾病分级精度计算。	
数据: 法结果和标签与DR和DME分级	
结果: 平均病分级精度DR和DME	
1	对于 $N=1, 2, \dots, n$ 做
2	正确= 0;
3	如果 ( $DR_{\hat{G}}(N) == DR_G(N)$ ) 和 ( $DME_{\hat{G}}(N) == DME_G(N)$ ) 然后
4	正确=正确+ 1;
5	结束
6	结束
7	平均准确= 正确 / $n$

6.3。次挑战 - 3

对于给定的视网膜图像, 子挑战的目标 - 3 ( 任务 - 6和7 ) 是预测OD和中央凹中心坐标。以CSV格式提交的结果的性能通过计算手册 ( 地面实况 ) , 并自动预测中心位置之间的欧几里得距离 ( 以像素为单位 ) 进行评价。较低的欧氏距离表示更好的定位。确定这些距离对于在Set-B的每个图像, 即用于103张图像后, 表示整个数据集的平均距离被计算并用于秩参与方法。

视盘分割 ( 任务 - 8 ) 性能是使用的Jaccard指数 ( 评价  $J$  ) ( 杰卡德, 1908年 )。它代表了分段OD之间的重叠面积的比例 (  $O$  ) 和地面实况 (  $G$  )。

$$J = \frac{|O \cap G|}{|O \cup G|} \tag{12}$$

更高  $J$  表明更好的分割。对于分割的结果, 图像在范围[0,255], 将其计算在10个不同的等间隔的阈值[0, 0.1, , 0.9]和平均, 以获得网络连接最终得分。

7.结果

该部分报告和讨论了所有subchallenges的结果。所有八个子任务设置-B在所有的竞争解决方案的性能被划分为三个子类别的挑战, 并讨论了包括其排行榜排名。

7.1。次挑战 - 1

在本节中, 我们提出了病变划分任务的所有竞争解决方案的性能。使用中给出的验证措施, 从参赛各队收到的所有结果进行了分析 第6.1节。产生这种措施的一组精确召回曲线的每个的不同的技术。在总共37支球队参加的挑战, 22支球队在子挑战-1, 其结果被评估参加 ( 完整列表, 请挑战网站 ), 使用AUPR值排名。他们当中, 7支队伍 ( 见 表5 ) 顶部内有性能在任何病变划分任务的4位被邀请的挑战车间及3支球队有更好的总体性能, 即解决方案由跻身前三名至少有三个不同的病变划分任务的团队开发, 提出了他们的在ISBI工作。

表8 总结在每个子任务的网络最终的放置顺序列出的每个解决方案的个人表现 ( 场外评价 )。它还包含各种方法遵循和外部数据集 ( 如果有的话 ) 用于训练模型。更高的等级指示的各个任务 ( S ) 更良好的性能。根据个体病变分割任务顶端-3项是VRT, 讯飞-MIG和PATech。一些样品病灶的分割结果中示出 图6 和它们对应的总体评价得分 表8 给出的评价得分如何与分割的质量关联更好的主意。 图7

总结了每个病变划分任务顶部4支球队的表现。不同的曲线表示关于各种病变 ( MAS, 的HE, SES和EXS ) 参与方法的性能。团队VRT实现最高AUPR得分HE和SE分割任务。然而, 团队PATech和科大讯飞, MIG分别获得EX和MA分割任务的最好成绩。

7.2。次挑战 - 2

本节介绍的结果通过参赛队伍的DR和DME分级任务完成 ( 现场评估 )。需要注意的是这个任务是为DR和DME的同时分级评价使用中列出的验证算法是非常重要的

6.2节 在Set-B。这个算法产生关节DR和DME上的所有图像的平均等级的精度。 表9 总结了队伍, 为与方法以及现场挑战的结果遵循和用于由各个球队训练模型的外部数据集。

在“现场”挑战的顶级表现的溶液提出了团队LzyUNCC其次是团队VRT和团队猛犸。 图8 节目竞争的解决方案, 为个人的平均准确度以及DR和DME的同时分级。团队观察到在DR等级的任务, 降低整体精度为DR和DME的同时分级表现不佳。主要的原因似乎是迪FFI邪教测试集, 在准确区分DR强度等级迪FFI culty。

7.3。次挑战 - 3

本节介绍的在次挑战参赛球队“现场”效果的评估 - 3, 所有三个子任务。通过计算欧几里德距离为OD和中央窝中心定位的子任务的结果进行评价, 而OD分割结果进行评估和排名使用Jaccard相似得分如所概述 6.3节。从现场评估结果以 表10 和 表11 汇总的所有三个子任务所有参与算法的性能。

本地化任务的获胜方法由团队DeepDR和团队VRT发达, 具有DeepDR表现最好的两个